

Pengantar Sains Data

Adila Alfa Krisnadhi, Dina Chahyati, Fariz Darari, Laksmita
Rahadiani, Lulu Ilmaknun Qurotaini, Siti Aminah, Aruni Yasmin
Azizah, Syifa Nurhayati, Tusty Nadia Maghfira

CSGE603130 - Kecerdasan Artifisial dan Sains Data Dasar
Semester Genap 2026/2027

- Stuart Russell & Peter Norvig, "Artificial Intelligence: A Modern Approach", 4th ed., 2020, Section 19.9.
- Windy Gambetta, "Metodologi Data Science", Salindia Modul Pelatihan Thematic Academy, Digital Talent Scholarship, Kemenkominfo 2021.
- Joel Grus, "Data Science from Scratch: First Principles with Python", 2nd ed., O'Reilly 2019.
- Gambar dan tangkapan layar hanya untuk kebutuhan penjelasan
 - Hak cipta tetap ada pada pemilik aslinya.

Motivasi di Balik Sains Data

Pengertian dan Lingkup Sains Data

Metodologi Sains Data

Studi Kasus

Data Reimagined

Motivasi di Balik Sains Data

Pengertian dan Lingkup Sains Data

Metodologi Sains Data


Studi Kasus

Data Reimagined

Kita bisa tahu tentang....

- Kata kunci apa yang paling sering dicari di Google?
- Halaman apa yang paling sering dikunjungi di Internet, dan berapa lama waktu yang pengunjung habiskan di sana?
- Apa yang sedang *trend* di X, Instagram, TikTok, Youtube?
- Berapa harga saham PT. Pantai Indah Kapuk Dua Tbk besok?
- Bagaimana sentimen orang terhadap DeepSeek di media sosial?
- Apa yang menyebabkan pengguna *e-commerce* meninggalkan keranjang belanja sebelum *checkout*?
- Lagu apa yang akan direkomendasikan untuk pengguna A besok?

... dengan *learning agent*!




Data these days..

... sangat dipengaruhi ketersediaan data yang masif: **Big Data**

- **Volume**: data terakumulasi sangat besar (terabyte, petabyte, exabyte, zettabyte, yottabyte, dst.)
- **Velocity**: data terhasikan sangat cepat (per detik, per menit, per jam, dst)
- **Variety**: ragam data semakin bermacam-macam: terstruktur, semi-terstruktur, tidak terstruktur (teks, suara, citra, video, dst)
- **Veracity**: kesesuaian data dengan fakta semakin sulit ditakar
- **Value**: kemampuan menghasilkan value dari data (profit, manfaat sosial, kepuasan pelanggan, dst.)
- **Variability**: variasi penggunaan data dalam pelbagai aplikasi

How?

Secara praktis, bagaimana ini direalisasikan?



- Data dapat dari mana? Apakah tersedia?
- Apakah setiap data cocok untuk dipakai?
- Bagaimana memilih representasi yang sesuai? Teks? Gambar?
- Bagaimana mengetahui bahwa hasil inferensi sudah baik?
- Bagaimana jika data berubah?
- Adakah efek tak diinginkan dari prediksi/inferensi?
- ...

Diperlukan serangkaian metode yang tertib dan sistematis...

Motivasi di Balik Sains Data

Pengertian dan Lingkup Sains Data

Metodologi Sains Data

Studi Kasus

Data Reimagined

Sains Data

- **Sains data (*data science*):** ekstraksi *insight* dari data yang *messy* (untuk pengambilan keputusan masa depan atau pemahaman masa lampau)
- **Ilmuwan data (*data scientist*)** = orang yang melakukan sains data, melingkupi
 - **descriptive data analytics:** menjelaskan keadaan bisnis saat ini melalui data historis/lampau.
 - **diagnostic data analytics:** menjelaskan mengapa suatu masalah muncul dengan melihat data historis.
 - **predictive data analytics:** memprediksi hasil di masa depan berdasarkan data historis.
 - **prescriptive data analytics:** merumuskan rekomendasi upaya terbaik di masa depan berdasarkan hasil analitika prediktif dan pengetahuan lain.


Examples

- Kata kunci apa yang paling sering dicari di Google?
- Halaman apa yang paling sering dikunjungi di Internet, dan berapa lama waktu yang dihabiskan di sana?
- Apa yang sedang *trend* di X, Instagram, TikTok, Youtube?
- Berapa harga saham PT. Pantai Indah Kapuk Dua Tbk besok?
- Bagaimana sentimen orang terhadap DeepSeek di media sosial?
- Apa yang menyebabkan pengguna *e-commerce* meninggalkan keranjang belanja sebelum *checkout*?
- Lagu apa yang akan direkomendasikan untuk pengguna A besok?
- dan masih banyak lagi

Examples


- Kata kunci apa yang paling sering dicari di Google?
- Halaman apa yang paling sering dikunjungi di Internet, dan berapa lama waktu yang dihabiskan di sana?
- Apa yang sedang *trend* di X, Instagram, TikTok, Youtube?
- Berapa harga saham PT. Pantai Indah Kapuk Dua Tbk besok?
- Bagaimana sentimen orang terhadap DeepSeek di media sosial?
- Apa yang menyebabkan pengguna *e-commerce* meninggalkan keranjang belanja sebelum *checkout*?
- Lagu apa yang akan direkomendasikan untuk pengguna A besok?
- dan masih banyak lagi

Area dasar sains data



Calvin.Andrus, CC BY-SA 3.0
 <<https://creativecommons.org/licenses/by-sa/3.0/>>,
 via Wikimedia Commons

KA vs Sains Data vs Big Data



Peran pelaku sains data

Belum ada standar; setiap industri/perusahaan bisa bervariasi

Data Engineer	Data Scientist	Business Stakeholder
Role: - Gathers, manages, and ensures the necessary data requirements - Builds and maintains the database Core skills: - Data ingest, ETL tools - Database systems - Distributed computing systems (Hadoop, Spark, dll.) - Data APIs - Unstructured data & data modeling - Data warehousing	Role: - Uses the data to model a problem to create an interpretation - Uses various models and machine learning approaches to estimate/analyze patterns Core skills: - Python, R - Distributed computing - Machine learning & deep learning - Feature engineering - Predictive modeling - Statistics & math - Storytelling & visualization	Role: - Computes Return on Investment (ROI), Net Present Value (NPV), and determines target/task based on domain expertise - Analyzes results for business decision making Core skills: - Business intelligence - Statistics & math - Data stewardship & management - Storytelling & visualization - Business communication

Bagaimana sistem KA dikembangkan dan dipakai?

- Tahap pengembangan/pelatihan (*training*)



Tahap pengembangan/pelatihan berfokus pada **membangun model** KA yang akurat dan *rigid* dengan memanfaatkan data yang ada.

- Tahap penggunaan



AI/DS Project Failures

- Gartner Research published a study in 2018: Only 15-20% AI/DS projects are completed, and only 8% gives value to the business
- Why?



Unclear or ill-formed problem, over-promised solution



Data issues



Incorrect modelling



Over-complicated algorithm



One-man show

<https://www.gartner.com/en/newsroom/press-releases/2018-02-13-gartner-says-nearly-half-of-cios-are-planning-to-deploy-artificial-intelligence>
<https://www.bmc.com/blogs/cio-ai-artificial-intelligence/>

Outline

Motivasi di Balik Sains Data


Pengertian dan Lingkup Sains Data

Metodologi Sains Data

Studi Kasus


Data Reimagined

KDD Process; Fokus teknis




Fayyad, Piatetsky-Shapiro, Smyth, "From Data Mining to Knowledge Discovery in Databases", AI Magazine 17(3): Fall 1996, 37-54
<https://www.kdnuggets.com/gpspubs/aimag-kdd-overview-1996-Fayyad.pdf>

Microsoft Data Science Lifecycle; Fokus bisnis dan teknis



CRISP-DM

- Cross-industry standard process for data mining; Fokus bisnis dan teknis



Kenneth Jensen, CC BY-SA 3.0, via Wikimedia Commons

Di Indonesia?

Standar Kompetensi Kerja Nasional Indonesia: Kepmenaker No 299 tahun 2020



TUJUAN UTAMA	FUNGSI KUNCI	FUNGSI UTAMA	FUNGSI DASAR
Menemukan pengetahuan, <i>insight</i> atau pola yang bermanfaat dari data untuk berbagai keperluan (orang mengambil keputusan atau sistem memproses lebih lanjut)	Menganalisis Kebutuhan (Requirements) Organisasi	<i>Business Understanding</i>	1. Menentukan objektif bisnis 2. Menentukan tujuan teknis 3. Membuat rencana proyek
		<i>Data Understanding</i>	4. Mengumpulkan data 5. Menelaah data 6. Memvalidasi data
	Mengembangkan model	<i>Data Preparation</i>	7. Memilah data 8. Membersihkan data 9. Mengkonstruksi data 10. Menentukan Label Data 11. Mengintegrasikan data
		<i>Modeling</i>	12. Membangun skenario pengujian 13. Membangun model
		<i>Model Evaluation</i>	14. Mengevaluasi hasil pemodelan 15. Melakukan review proses pemodelan
	Menggunakan model yang dihasilkan	<i>Deployment</i>	16. Membuat rencana deployment model 17. Melakukan deployment model 18. Melakukan rencana pemeliharaan 19. Melakukan pemeliharaan
		<i>Evaluation</i>	20. Melakukan review proyek 21. Membuat laporan akhir proyek

Outline

Motivasi di Balik Sains Data

Pengertian dan Lingkup Sains Data

Metodologi Sains Data

Studi Kasus

Data Reimagined

1. Business Understanding

- Fokus pada definisi problem bisnis:

“What problem are you trying to solve?”

- Tahapan yang umumnya terjadi
 - Business owner: “How can we reduce the costs of performing an activity?”
 - Interpretasi: “Is it to improve the efficiency of the activity?” or “Is it to increase business profitability?”
 - Tentukan tujuan spesifik
 - Tentukan pendekatan analitik yang tepat berdasarkan tujuan
 - descriptive → “Apa yang terjadi?”
 - diagnostic → “Mengapa ini terjadi?”
 - predictive data → “Apa yang mungkin terjadi di masa depan?”
 - prescriptive → “Apa yang harus dilakukan?”

Business Understanding: Case Studies

Business owner: **Pankreatitis Akut** (Acute Pancreatitis/AP) merupakan salah satu diagnosis yang umum pada unit perawatan intensif (ICU). Tingkat kematian pasien AP di ICU berkisar antara 1% hingga 5%, dengan kelompok pasien berisiko tinggi memiliki faktor klinis dan laboratorium yang lebih buruk. Rumah sakit menghadapi tantangan dalam **alokasi sumber daya**, karena sulitnya mengidentifikasi pasien dengan risiko tinggi sehingga menyebabkan keterlambatan dalam **intervensi medis**. Selain itu, jumlah kasus AP yang terus meningkat semakin **membebani finansial layanan kesehatan**.

- **Bagaimana rumah sakit dapat mengalokasikan sumber daya yang terbatas untuk memaksimalkan perawatan yang efisien dan berkualitas?**
- Tujuan spesifik:
- Pendekatan analitik:
- Pemilihan model:

Business Understanding: Pankreatitis Akut (2)

Business owner: **Pankreatitis Akut** (Acute Pancreatitis/AP) merupakan salah satu diagnosis yang umum pada unit perawatan intensif (ICU). Tingkat kematian pasien AP di ICU berkisar antara 1% hingga 5%, dengan kelompok pasien berisiko tinggi memiliki faktor klinis dan laboratorium yang lebih buruk. Rumah sakit menghadapi tantangan dalam **alokasi sumber daya**, karena sulitnya mengidentifikasi pasien dengan risiko tinggi sehingga menyebabkan keterlambatan dalam **intervensi medis**. Selain itu, jumlah kasus AP yang terus meningkat semakin **membebani finansial layanan kesehatan**.

- **Bagaimana rumah sakit dapat mengalokasikan sumber daya yang terbatas untuk memaksimalkan perawatan yang efisien dan berkualitas?**
 - Memaksimalkan sumber daya → akan butuh biaya yang banyak
 - Meminimalkan dampak pankreatitis akut → memprediksi risiko keparahan/kematian pasien AP di ICU
- Tujuan spesifik: “Diberikan data historis pasien AP di ICU, bagaimana risiko keparahan/kematian pasien tersebut?”
- Pendekatan analitik: Klasifikasi (memiliki risiko kematian vs tidak)
- Pemilihan model: Decision tree

2. Data Understanding

- Tentukan prasyarat data yang sesuai dengan problem bisnis
 - Konten, format, representasi, dll.
- Lakukan pengumpulan data (bisa terstruktur, takterstruktur, semi terstruktur)
- Pahami data menggunakan statistika dan visualisasi
- Iterasi jika perlu

Data Understanding : Pankreatitis Akut

- **Data requirements:** mengambil kelompok pasien yang sesuai
 - Pasien berumur > 18 tahun
 - Terdaftar di ruang ICU setidaknya 1x24 jam. Jika terdapat lebih dari satu data, maka yang diambil adalah yang terbaru.
 - Memiliki kriteria atau diagnosis Pankreatitis Akut; melalui kode diagnosis dan/atau hasil lab yang sesuai.
- **Data collection:** catatan kesehatan elektronik yang terintegrasi dari rumah sakit.
- Sesuaikan format, konten, dan representasi data dengan pemodelan analitik yang dipilih.
 - Pemodelan dilakukan dengan memprediksi kemungkinan risiko per pasien
→ data harus disediakan dalam format 1 entri per pasien dengan kolomnya merepresentasikan variabel
 - Klasifikasi → membutuhkan label target, tandai pasien yang meninggal dengan risiko tinggi kematian dan sisanya tidak.
 - Definisikan variabel yang dibutuhkan: data pendaftaran pasien, data historis lab, data historis perangkat digital medis di ICU.
- Lakukan analisis statistik dan visualisasi pada data.

3. Data Preparation

- Mencakup semua aktivitas menyiapkan dataset untuk modeling
 - ***Cleaning***, mengintegrasikan data dari banyak sumber, membersihkan duplikasi dan *missing data*, dan lain-lain
 - ***Feature engineering*** untuk mendapatkan variabel prediktor baru, dan meningkatkan kinerja
- Paling memakan banyak waktu: 70-90% waktu proyek (bisa kurang jika sumber data sudah terkelola dengan baik).

Lebih lanjut di Topik: Data collection, data understanding/EDA, Statistics, Data preparation: cleaning, transformation, Dimensionality Reduction

Data Preparation : Pankreatitis Akut

- Menggabungkan variabel dari sumber berbeda
 - **Data pendaftaran pasien:** ID, jenis kelamin, umur, tanggal kematian, kebiasaan (merokok/alkohol)
 - **Data historis lab dan klinis:** ID, kadar darah putih, platelet, creatinine, glukosa, hematocrit, blood ure nitrogen, kadar lipase, anion gap, prothrombin time, bilirubin, dll.
 - **Data historis perangkat digital medis di ICU:** ID, tekanan darah, alarm detak jantung, length of stay
- *Cleaning*
 - Hanya mengambil data dalam durasi 24 jam setelah pendaftaran (reaksi awal pada perawatan)
 - Menghapus data terduplikasi
 - Menghapus entri yang memiliki data historis lab dan klinis yang kosong hingga >20%
- *Feature engineering*
 - Agregasi data historis pada level pasien dengan menggunakan rerata

4. Modeling

- Dimulai dari dataset yang sudah disiapkan (dari tahap data preparation), model prediktif atau deskriptif dikembangkan sesuai pendekatan yang dipilih dari tahap business understanding
- Bersifat iteratif: perlu melakukan beberapa kali eksperimen hingga kinerja memuaskan.

Lebih lanjut di Topik: Classification and regression tree (CART); Nearest neighbor classification and regression; Likelihood & Naive Bayes; Linear Regression; NN; Clustering

5. Evaluation

- Ilmuwan data:
 - mengevaluasi kualitas model
 - memeriksa apakah model sudah mengatasi masalah bisnis secara baik dan menyeluruh
- Membutuhkan penghitungan macam-macam ukuran kinerja serta sajian visual (tabel, graf) pada dataset uji.

Lebih lanjut di Topik: Supervised model evaluation, evaluation metrics; Imbalanced Classification

Evaluation : Pankreatitis Akut

- Evaluasi: **Apakah model yang digunakan benar-benar menjawab pertanyaan awal, atau perlu disesuaikan?**
- Kunci untuk memastikan relevansi model dalam menjawab permasalahan adalah dengan membuat *business stakeholders* memahami alat yang telah dibuat.
- Dalam skenario bisnis, business stakeholders akan memiliki keahlian yang berbeda-beda yang berperan dalam keberhasilan implementasi, seperti tim pemasaran, pengembang aplikasi, dan administrasi IT.
- Setelah model dievaluasi dan *data scientist* yakin model tersebut berfungsi dengan baik, langkah berikutnya adalah menerapkannya dan mengujinya dalam kondisi nyata.

6. Deployment

- Setelah model sudah sesuai dengan permasalahan bisnis, model di-deploy pada lingkungan produksi.
- Deployment awal difokuskan pada evaluasi kinerja awal pada lingkungan riil.
 - A/B testing banyak dipakai di sini.
- Deployment lebih luas pada proses bisnis secara operasional membutuhkan keterlibatan banyak pihak/bagian dalam organisasi.
- Setelah deployment diinisiasi, proses tidak berhenti.
 - Perlu evaluasi secara berkesinambungan untuk terus memperbaiki model.
 - Prinsip: "Machine learning models always get worse over time" (due to the presence of new data).

Studi Kasus: Pankreatitis Akut

- Setelah model melewati masa evaluasi, model siap untuk diujikan pada kasus nyata secara *real time*.
- Langkah selanjutnya:
 - Membagikan pengetahuan dan berkomunikasi kepada tim bisnis (pihak manajemen rumah sakit).
 - Tim bisnis akan melakukan penyuluhan lebih lanjut kepada petugas klinis tentang hasil keluaran model agar petugas klinis dapat memahami cara mengidentifikasi pasien berisiko tinggi dan merancang tindakan intervensi yang sesuai.
- Umpan balik dari pengguna dikumpulkan untuk membantu penyempurnaan model serta mengevaluasi kinerja dan dampaknya.

Deploying a Data/AI Application


- It may function, but you can't sell this y

```

Command Prompt
C:\Users\Laksmi Rahadianti\Desktop\Demo\OL pekan11>javac QuotientWithException.java
C:\Users\Laksmi Rahadianti\Desktop\Demo\OL pekan11>java QuotientWithException
Enter two integers: 2
0
Divisor cannot be zero
Exception: an integer cannot be divided by zero
Execution continues ...



C:\Users\Laksmi Rahadianti\Desktop\Demo\OL pekan11>
  
```

- Now you can sell it!




The Double Loop

The AI Product Development Lifecycle



Responsible AI With Humans In The Loop



<https://humansintheloop.org/>
<https://www.titanml.co/glossary/human-in-the-loop>

Outline

Motivasi di Balik Sains Data

Pengertian dan Lingkup Sains Data

Metodologi Sains Data

Studi Kasus

Data Reimagined

Studi Kasus: *Bodies as Data*

Berikut adalah cuplikan dataset “Human Body Measurement”


ID	Age	Height (cm)	Weight (kg)	BMI	Body Fat (%)	Muscle Mass (kg)	Heart Rate (bpm)	Daily Steps	Sleep Hours
1	25	175	68	22.2	15.0	32.5	72	8000	7.5
2	17	160	75	29.3	25.5	28.0	80	5000	6.0
3	23	170	82	28.4	23.0	31.5	76	6000	6.8
4	24	180	90	27.8	20.0	35.0	65	9000	8.0
5	19	165	70	25.7	22.0	29.5	85	4000	5.5
6	22	178	74	23.4	17.0	33.0	70	10000	7.2

Dataset seperti ini umumnya disebut dengan **dataset tabular**.

Studi Kasus: *Bodies as Data*

Apa analisis yang bisa kita lakukan pada dataset “Human Body Measurement”?

1. Bisakah kita membuat rekomendasi rencana kebugaran atau diet yang dipersonalisasi berdasarkan statistik tubuh?



Hasil dan Diskusi:

Data bisa dikategorisasi menjadi tiga kelompok


- Kelompok 1:** BMI tinggi, Body fat tinggi
 Rekomendasi: Fokus pada penurunan **kadar lemak**, tingkatkan olahraga kardio & sesuaikan diet untuk menurunkan kalori
- Kelompok 2:** BMI tinggi, Body fat normal
 Rekomendasi: Fokus mempertahankan **masa otot**, bisa melakukan *strength training* dan makanan seimbang gizi dengan cukup protein
- Kelompok 3:** BMI normal, Body fat rendah
 Rekomendasi: Fokus meningkatkan **endurance**, lakukan gabungan latihan kardio dan kekuatan, fokus pada pembentukan otot.

Studi Kasus: *Bodies as Data*


Apa analisis yang bisa kita lakukan pada dataset “Human Body Measurement”?

2. Bisakah kita memprediksi BMI seseorang dan mengkategorikan individu menjadi kurang berat badan, normal, kelebihan berat badan, dan obesitas?
→ Regresi, Klasifikasi, Clustering
2. Bisakah jumlah langkah harian memprediksi massa otot dan persentase lemak tubuh?
→ Regresi
2. Bagaimana persentase lemak tubuh dan massa otot berubah seiring bertambahnya usia?
→ Time-series forecasting
2. Dan masih banyak lagi...

Studi Kasus: *Words as Data*




Harry Potter and the Deathly Hallows by J.K. Rowling



Data seperti ini biasa disebut sebagai **data tekstual**

Studi Kasus: *Words as Data*




Šiljak, Harun. (2022). Networks of Twin Peaks: The Dale Cooper Effect. *The Mathematical Intelligencer*. 45. 1-7. 10.1007/s00283-022-10187-w.

Studi Kasus: *Pictures as Data*

Data citra satelit di sampling digunakan untuk memprediksi **GDP** suatu negara dengan menghitung perkembangan **penggunaan lampu/cahaya** sebagai indikator **perkembangan aktivitas ekonomi**.

Henderson JV, Storeygard A, Weil DN. MEASURING ECONOMIC GROWTH FROM OUTER SPACE. Am Econ Rev. 2012 Apr;102(2):994-1028. doi: 10.1257/aer.102.2.994. PMID: 25067841; PMCID: PMC4108272.



Lebih banyak hal yang bisa dilakukan dengan sains data!

Banyak berimajinasi → banyak eksplorasi → banyak pertanyaan → banyak ide